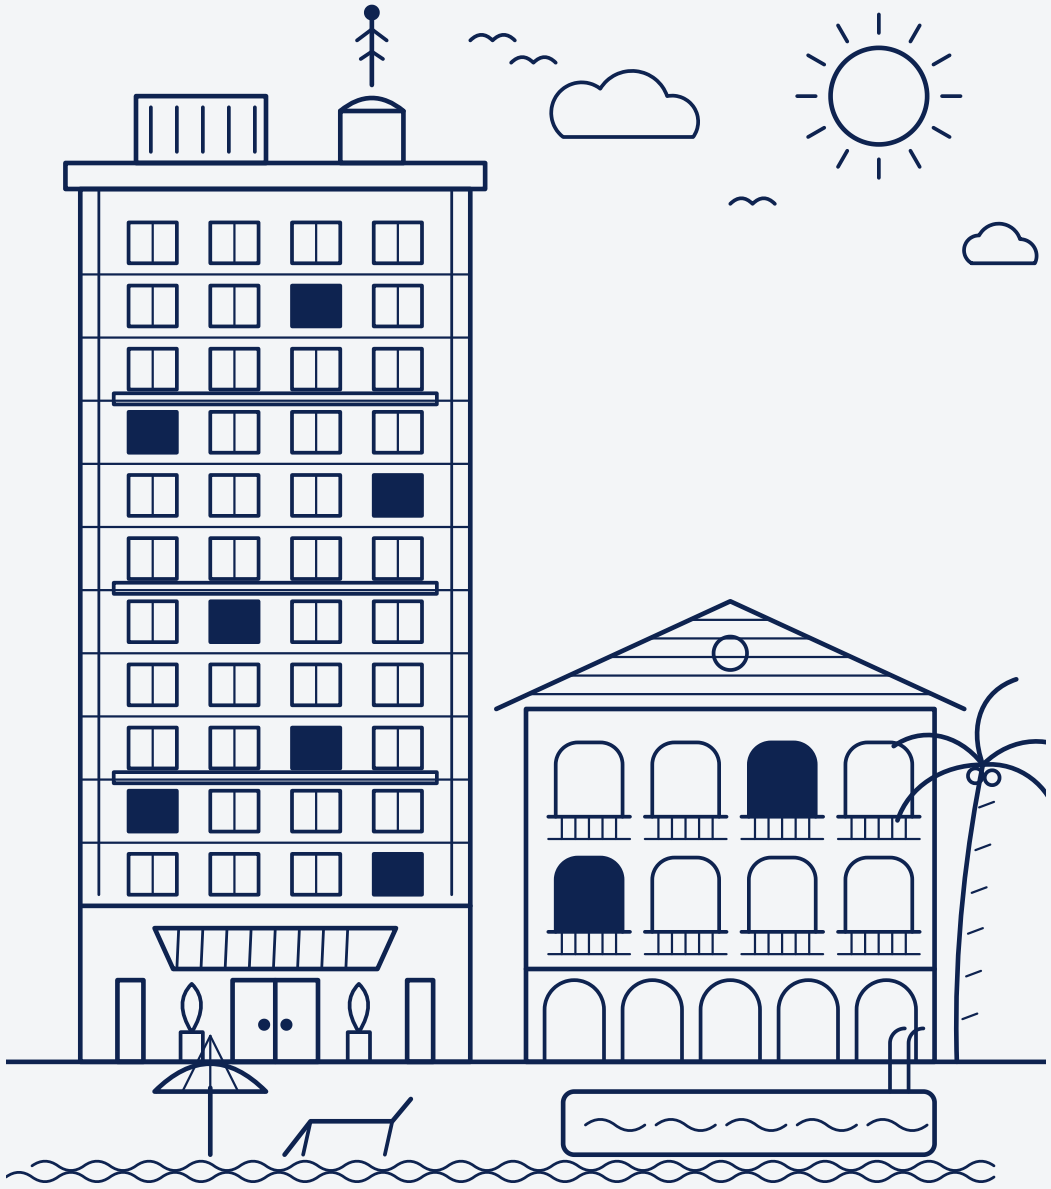
Итоговый проект программы ДПО НИУ ВШЭ «Аналитика данных»
Лобастов Иван Павлович, 2026

Отмены бронирований в отелях: прогноз и политика предоплаты

Какие брони отменят и сколько отель сэкономит, если брать предоплату только с рискованных?



Каждая четвёртая бронь отменяется, и отель теряет деньги

27,7 %

броней отменяется

2,11 млн €

потери без предоплаты за май–август 2017

Оценка: в данных нет, перепродан ли освободившийся номер, поэтому считаю, что отель теряет половину стоимости отменённых броней. Если теряет 30–70 %, потери 1,27–2,95 млн €.

Предоплата со всех снижает потери, но её платят и надёжные гости, которые и так приехали бы.

Задача проекта

1. Найти, по каким закономерностям отменяют брони.
2. Оценить риск отмены каждой брони и решить, с каких брать предоплату.
3. Посчитать выгоду в деньгах и дать рекомендацию бизнесу.

Реальные брони двух отелей в Португалии за 2015–2017 годы

Hotel Booking Demand

Брони из систем бронирования двух отелей, заезды с июля 2015 по август 2017. Antonio, Almeida, Nunes, *Data in Brief*, 2019.

79 330

строк — городской отель, Лиссабон

40 060

строк — курортный отель, Алгарви

Что известно о каждой брони: 32 колонки

Когда	за сколько дней до заезда сделана бронь, дата заезда, ночей в будни и выходные, дней в листе ожидания
Кто	отель, взрослые, дети, младенцы, страна, повторный ли гость, его прошлые отмены и поездки
Через кого	сегмент продаж, канал, агент, компания, тип клиента
На каких условиях	депозит, питание, заказанный и выданный номер, цена за ночь, парковка, спецзапросы, число изменений
Чем закончилась	отменена или нет, итоговый статус (выезд, отмена, неявка) и его дата

Ошибки ввода удалил, а повторы строк оказались групповыми бронями

Ошибки и пропуски

Удалено 847 строк

715	на 0 ночей: визиты на день
110	без единого гостя
15	до 55 гостей в одном номере
5	неизвестный сегмент или канал
2	цена −6,38 € и 5 400 € за ночь

Исправлено без удаления

1 160	питание «не указано» → без питания
473	пустая страна → «неизвестно»
4	пустое число детей → 0

Повторы строк: как пришёл к склейке

1. **31 994 строки** полностью повторяют другие — почти четверть файла. С ними отмен 37,0 %, без них 27,5 %.
2. Повторы там, где бронируют сразу несколько номеров: **75 %** строк «Групп», 43 % офлайн-агентств, 93 % броней с депозитом «без возврата».
3. Одинаковые строки идут пачками: 5 034 пары, 969 троек и 914 пачек от 10 до 180 строк — случайно так не совпадает.
4. Номера брони в файле нет: авторы убрали его при обезличивании. Значит, повтор — это **номер той же групповой брони**.

Что делать с повторами

Удалить повторы
теряю реальные номера и деньги

Оставить как есть
одна отмена группы считается десятком

Склеить в одну бронь
с числом номеров — выбрал это

Без очистки групповые брони выглядят вдвое опаснее

118 543

строк из 119 390 осталось после удаления ошибок ввода

86 617

броней после очистки: одинаковые строки склеены в групповые брони

61 → 27 %

отмен у «Групп»: если считать каждую строку и по броням

Сегменты продаж в исходном файле

число строк

Онлайн-агентства	56 477
Офлайн-агентства	24 219
Группы	**19 811**
Прямые	12 606
Корпоративные	5 295
Бесплатные	743
Авиакомпании	237
Не указан	2

«Групп» много, но 75 % их строк — повторы: каждый номер групповой брони записан отдельной строкой. Повторы объединил в одну бронь.

Так одна групповая бронь записана в исходном файле

строка файла	отель	заезд	ночей	бронь за	цена за ночь	сегмент	отмена
56 782	городской	14.09.2016	2	41 дн.	130 €	Группы	да
56 783	городской	14.09.2016	2	41 дн.	130 €	Группы	да
56 784	городской	14.09.2016	2	41 дн.	130 €	Группы	да
56 786	городской	14.09.2016	2	41 дн.	130 €	Группы	да
56 789	городской	14.09.2016	2	41 дн.	130 €	Группы	да
56 790	городской	14.09.2016	2	41 дн.	130 €	Группы	да

и ещё 6 точно таких же строк

Шесть гипотез из вопросов бизнеса: все подтвердились, но сила связи разная

Как проверял

1. **Гипотезы — до анализа**, из вопросов отеля: с кого брать предоплату, с кого не брать.
2. **Статистический тест** на каждую: χ^2, z-тест для долей, Краскел — Уоллис.
3. **Поправка Холма**: проверок шесть, поэтому порог $p < 0{,}05$ строже.
4. **Размер эффекта**: на 86 тыс. броней значима почти любая разница, важна её величина.
5. **Устойчивость**: повторил на данных без склейки повторов и без броней «без возврата».

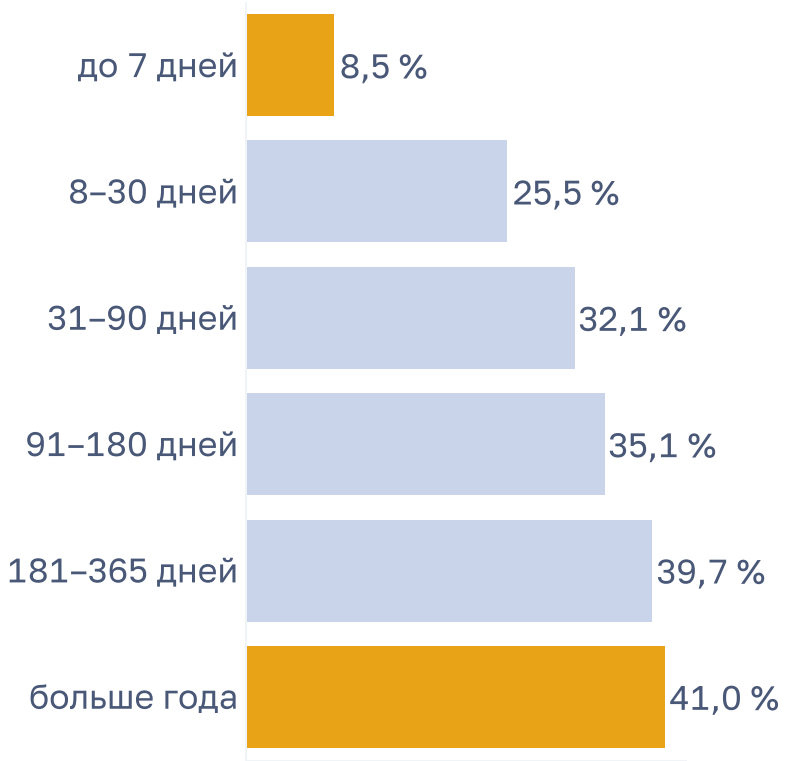
Гипотезы и что показали данные

	гипотеза	результат
H1	**Чем раньше бронируют, тем чаще отменяют**	**8,5 % за неделю, 41,0 % больше чем за год**
H2	**Сегменты продаж различаются по доле отмен**	**онлайн-агентства 35,5 %, прямые и корпоративные 12–15 %**
H3	Гости со спецзапросами отменяют реже	на 11,6 п. п. реже
H4	Повторные гости отменяют реже	8,2 % против 28,4 %
H5	Городской отель теряет на отменах больше курортного	отмен больше на 6,5 п. п.
H6	Цена у курорта сильнее зависит от сезона	сезон объясняет 60 % разброса цены против 18 %

Во всех шести p с поправкой < 0,001. H1 и H2 — основа правила предоплаты, их графики на следующем слайде.

Чаще отменяют ранние брони и брони через онлайн-агентства

Доля отмен по сроку брони



Доля отмен по сегменту



Это связь, а не причина: срок брони сам по себе гостя не отменяет.

Нужна оценка риска каждой брони в момент бронирования

1

Новая бронь

Известны срок брони, сегмент, канал продаж, депозит, спецзапросы.

→

2

Модель

Оценивает риск отмены этой брони — от 0 до 100 %.

→

3

Порог

Риск выше порога — бронь с предоплатой, ниже — без неё.

→

4

Деньги

Считаю потери от отмен и сколько надёжных гостей задела предоплата.

Почему модель, а не одно правило

Признаков много, и действуют они вместе: срок брони, сегмент и спецзапросы по отдельности дают лишь часть картины. Модель учитывает их все сразу и ставит каждой брони свой риск.

Модель учится на прошлом и проверяется на будущем: 60 / 20 / 20

Брони поделены по дате заезда

время →

60 % обучение

на них модель училась

20 % валидация

сравнил модели, выбрал порог риска 0,17

20 % экзамен

проверка на бронях, которых модель не видела



07.2015–11.2016

51 926 броней, отмен 24,7 %

11.2016–05.2017

17 340 броней, отмен 29,3 %

05.2017–08.2017

17 351 бронь, отмен 34,8 %

Без подглядывания в ответ

Колонки, которые заполняются позже (итог брони, выданный номер, число изменений), исключены.

Почему по времени

Как в жизни: модель учится на прошлом и предсказывает будущее. Случайное деление завысило бы качество: **0,683 вместо 0,626**.

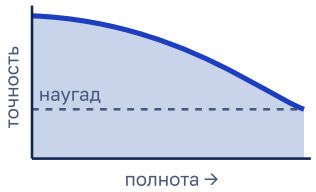
Почему 60 / 20 / 20

Доли выбраны до результатов. Экзамен — весь сезон май–август, 17 351 бронь, а не только июль–август, как при 75/15/10. На 5 месяцах валидации выбирал модель и порог.

Модель выбрана на валидации: CatBoost немного лучше остальных

PR-AUC на валидации, ноябрь 2016 — май 2017: чем больше, тем лучше





Что такое PR-AUC

Модель ставит каждой брони риск, брони выстраиваются по нему сверху вниз. Идём по списку и считаем две доли: **точность** — сколько из отмеченных броней правда отменили, **полнота** — какую часть всех отмен уже нашли. PR-AUC — площадь под этой кривой.

1 — все отмены в самом верху списка; **≈ 0,29** — наугад, это просто доля отмен на валидации.

Что такое CatBoost

Много небольших деревьев-правил вида «бронь больше чем за 90 дней через онлайн-агентство — риск выше». Каждое следующее дерево исправляет ошибки предыдущих.

Почему он

Сам работает с текстовыми признаками (сегмент, тип клиента), лучший на валидации, каждый прогноз можно объяснить. Перевес небольшой: 0,640 против 0,632 и 0,621.

Как настроил

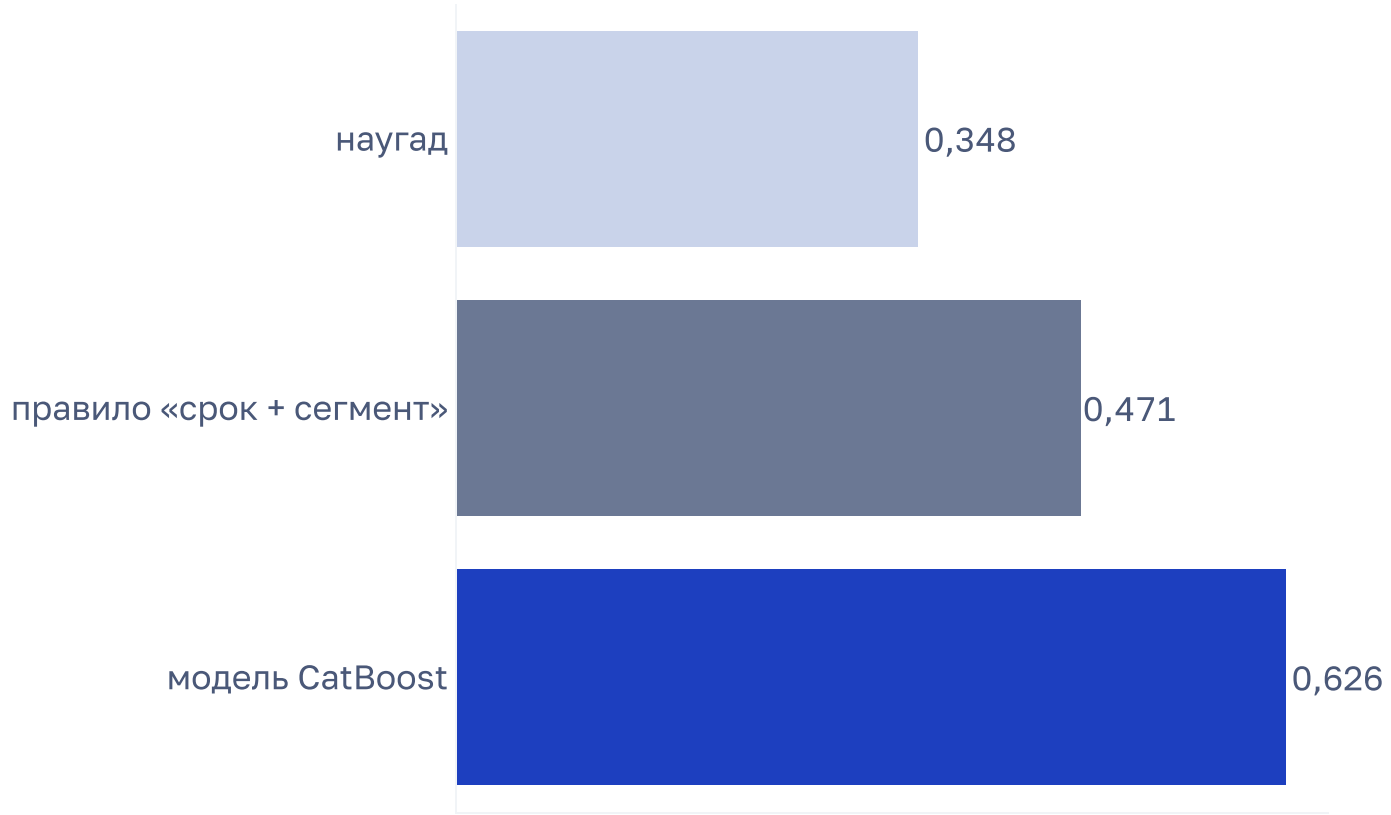
6 сочетаний: глубина деревьев 4, 6, 8 и скорость обучения 0,05 и 0,1; деревья добавлялись, пока качество росло. Итог: глубина 4, 335 деревьев.

Модель ставит будущие отмены вперёд почти вдвое лучше угадывания

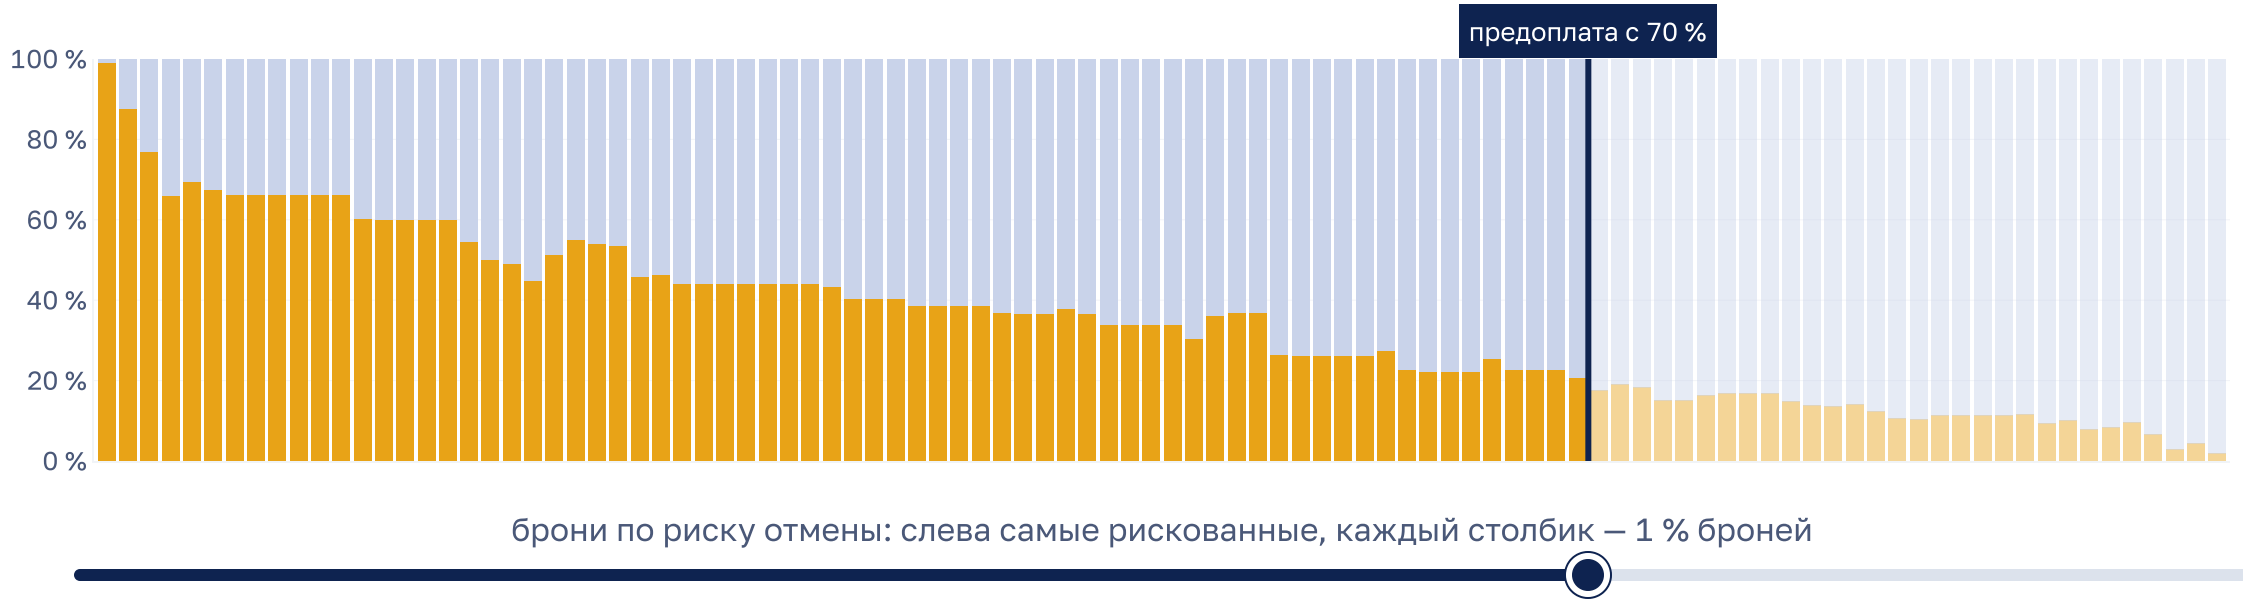
0,626

PR-AUC на экзамене: от 0 до 1, насколько хорошо модель ставит отмены выше остальных броней. Наугад — 0,348, это просто доля отмен.

PR-AUC на экзамене, май–август 2017



Брони выстроены по риску: черта решает, кто платит предоплату



Предоплата с **70** % самых рискованных броней

0,56 млн €
потери

1,55 млн €
экономия

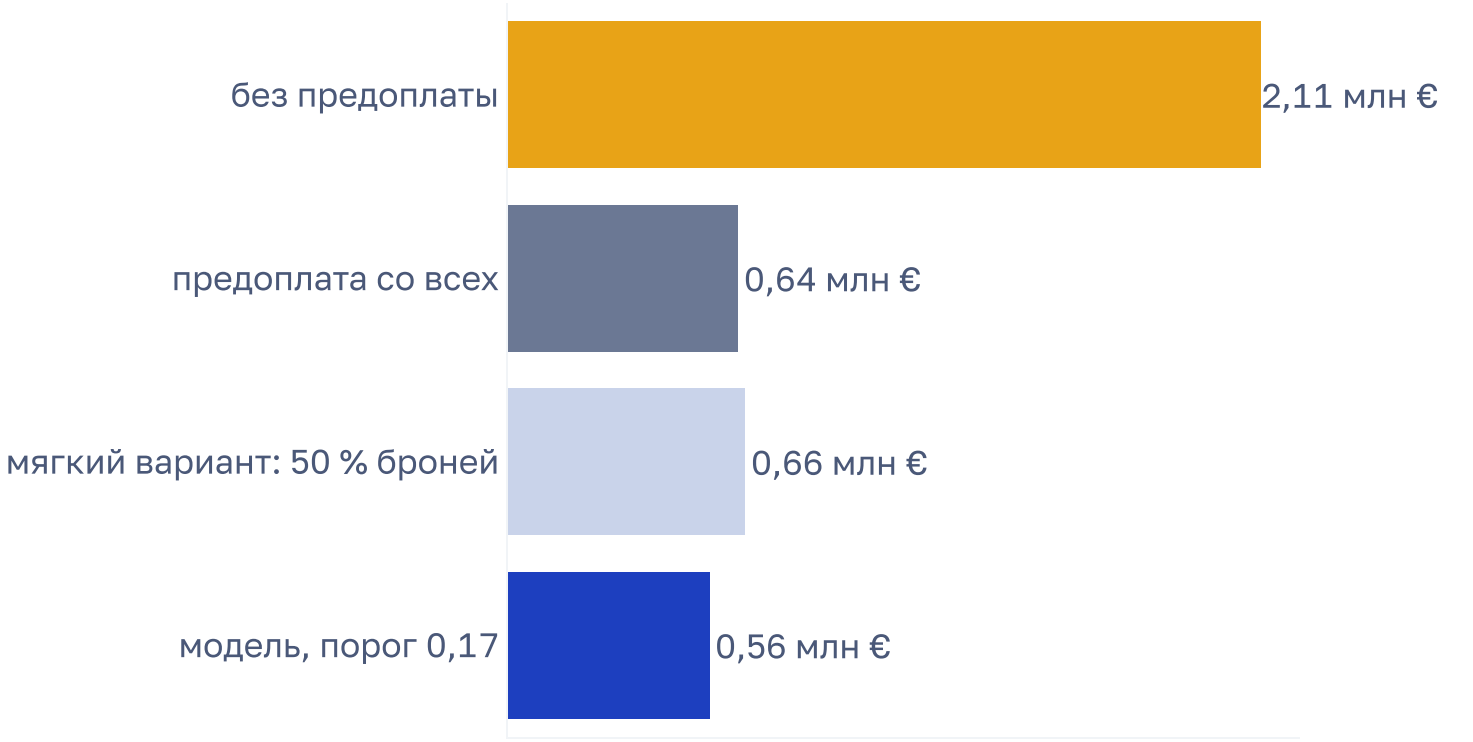
90 %
отмен под предоплатой

60 %
надёжных гостей платят

Экономия — против 2,11 млн € потерь без предоплаты. Порог 0,17 (70 % броней) выбран на валидации, до экзамена.

Предоплата по модели снижает потери с 2,11 до 0,56 млн €

Потери на экзамене, млн €



+0,08 млн €

столько модель добавляет к предоплате со всех (0,64 млн €); основную экономию даёт сама предоплата, без неё — 2,11 млн €

0,56 против 0,79

млн € при предоплате с 70 % броней: выбирать брони моделью лучше, чем по сроку брони

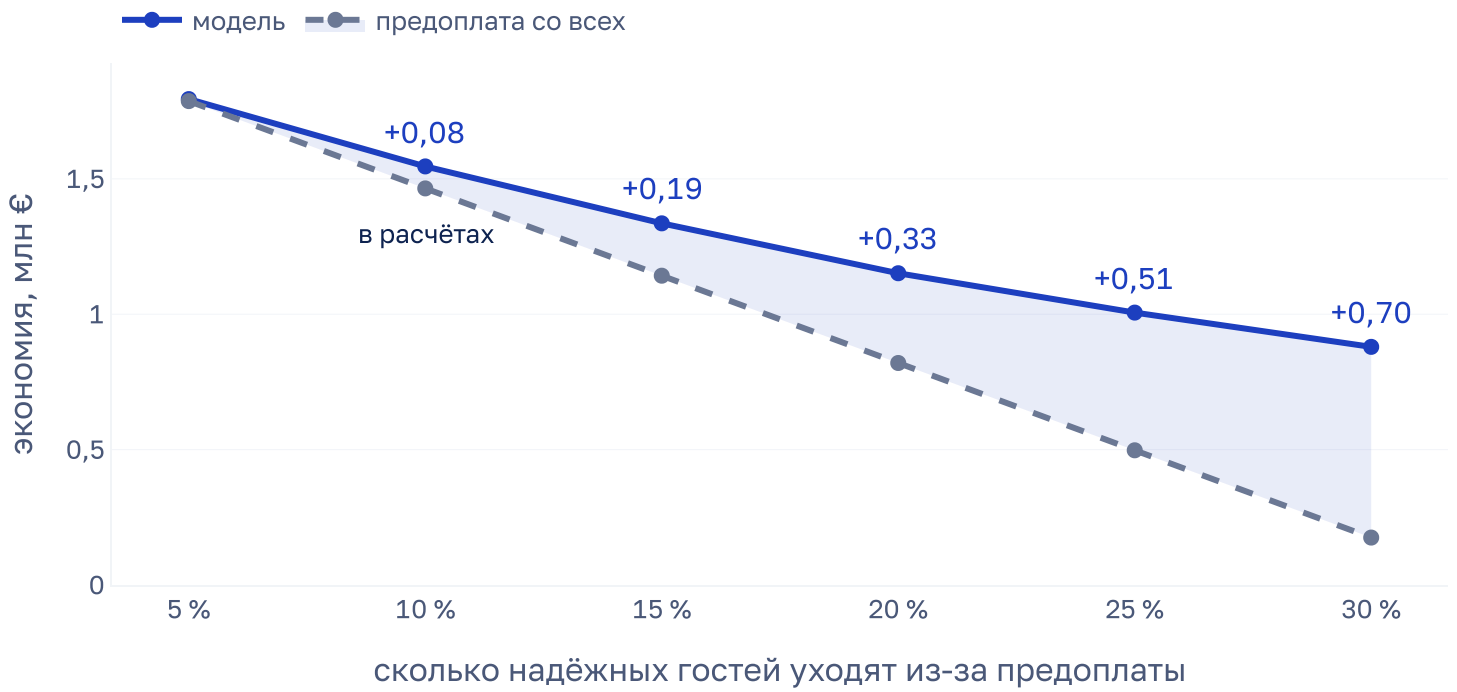
0,66 млн €

мягкий вариант, предоплата с 50 % броней

Овербукинг по модели — до 3,15 млн €, это верхняя оценка; с итогом предоплаты её не складывают.

Чем чаще уходят надёжные гости, тем больше выигрыш модели

Экономия на экзамене против работы без предоплаты, млн €



+0,08 млн €

выигрыш модели над «со всех», если уходят 10 % надёжных гостей — как в расчётах

+0,33 млн €

если уходят 20 %: вчетверо больше; при 30 % — +0,70 млн €

Модель лучше при любом допущении

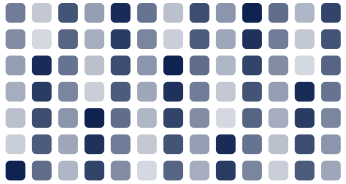
Во всех 20 сочетаниях (уход гостей 5–20 %, неперепроданная доля 30–70 %) лучшее правило — модель, ноутбук 04.

10 % — допущение: реакции гостей на предоплату в данных нет. Порог модели пересчитывается под допущение: при 10 % это 0,17, при 20 % — 0,29. Экономия — против 2,11 млн € потерь без предоплаты, они от ухода гостей не зависят.

Как считал овербукинг: от риска каждой брони к номерам сверх броней

Расчёт на каждую дату — средний день мая–августа 2017, оба отеля

1



≈ 143 брони на дату
у каждой свой риск отмены из модели

2

Σ рисков
50

В среднем отменят 50
сумма рисков всех броней — ориентир для прицеливания, от него считаю запас

3



Продаю с запасом: 41, а не 50
запас такой, чтобы гостю не хватило номера не чаще чем в 1 дне из 10

4



Что вышло на деле
Отменили в среднем 50 — проданные номера заняли новые гости; всем хватило в 85 % дней. Доход **≈ +26 тыс. € в день**

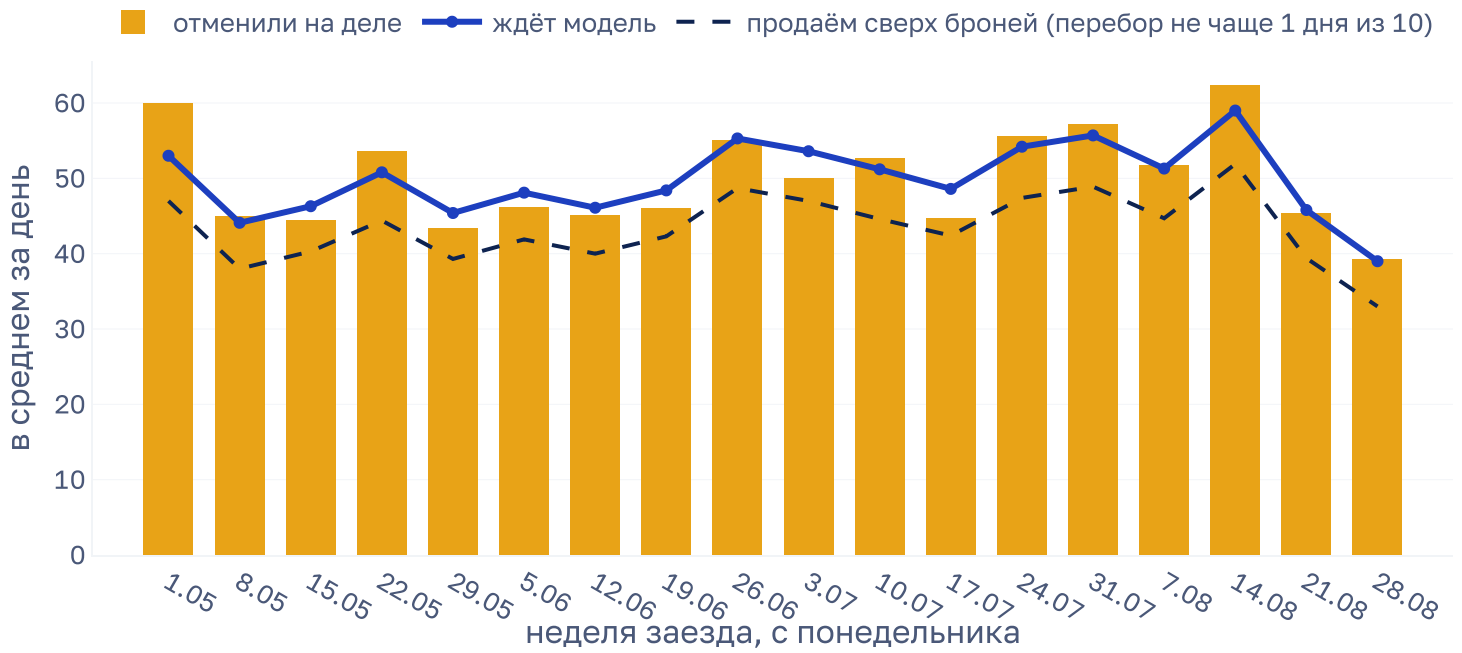
Почему 41, а не 45 = 90 % от 50: «1 из 10» — это про дни, а не про номера

условные 10 дней, отменили	40	43	47	49	51	52	53	55	56	54	в среднем 50
продаю 45 — это 90 % от 50	✗	✗	✓	✓	✓	✓	✓	✓	✓	✓	**ошибка в 2 днях из 10 — много**
продаю 41	✗	✓	✓	✓	✓	✓	✓	✓	✓	✓	**ошибка в 1 дне из 10 ✓**

По каждому отелю отдельно: свободный номер в курортном не поможет гостю городского. **Без модели** — тот же расчёт по доле отмен «месяц × день недели»; гость без номера стоит одну его бронь.

Овербукинг по модели — до 3,15 млн € за сезон, но это верхняя оценка

Экзамен, май–август 2017, по неделям: модель ждёт почти столько отмен, сколько было



41 номер в день

в среднем за май–август продано сверх броней. Модель ждала в среднем 50 отмен в день — продавал меньше, с запасом

3,15 млн €

по модели: перепродано 4 898 номеров. По средней доле отмен «месяц × день недели» — 2,39 млн €

90 гостей

не хватило бы номера: 0,05 млн € компенсаций, уже вычтены из итога

Верхняя оценка: вместимости в данных нет, и считаю, что на каждый перепроданный номер найдётся покупатель. В городском отеле перебор случился в 27 % дат вместо 1 из 10 — овербукировать по отелю отдельно и с запасом. С итогом предоплаты не складывается.

Допущения работы и что можно улучшить

Допущения

Групповые брони	Идентификатора брони нет: одинаковые строки склеены в групповые брони.
Вместимость	Её нет в данных: овербукинг посчитан сверх забронированного, поэтому это верхняя оценка.
Деньги	50 % отменённых номеров отель успевает перепродать. 10 % надёжных гостей уходят из-за предоплаты. Влияние этих долей проверено в ноутбуке 04.

Что можно улучшить

Каждый отель отдельно	Настраивать вероятности отмен отдельно для каждого отеля.
Групповые отмены	Группы отменяют много броней разом: в городском отеле оценка овербукинга ошиблась в 27 % дат вместо 10 %.
Скоринг в реальном времени	Сервис сам оценивает риск каждой новой заявки и по заданному порогу решает, брать предоплату или нет.

Итог: +1,55 млн € на предоплате и до +3,15 млн € на овербукинге за сезон

Предоплата по риску отмены

+1,55 млн €

сэкономлено за май–август 2017 против работы без предоплаты

потери за сезон, млн €



Решение: предоплата с броней, у которых риск отмены выше 0,17 — это 70 % броней. Мягче — с 50 %: +1,45 млн €, платят 37 % надёжных гостей.

Овербукинг по модели

до +3,15 млн €

дополнительный доход: 4 898 номеров продано сверх броней, если каждый купят

дополнительный доход за сезон, млн € (средняя доля — по «месяцу × дню недели» прошлых лет)



Решение: продавать сверх броней по каждому отелю отдельно и с запасом — группы отменяют много номеров разом.

Не складываются

Обе суммы зарабатываются на одних и тех же отменах — сложить их в одну нельзя.

Качество модели

0,626 против 0,348: отмены вверху её списка почти вдвое чаще, чем наугад.

Вклад модели в предоплату

+0,08 млн € сверх «со всех», если уходят 10 % надёжных гостей; +0,33 — если 20 %.

Рекомендация на 2018 год: предоплата по риску, ожидаемо около +2,9 млн € в год

Кому брать предоплату в 2018 году

предоплата · без предоплаты · · мало данных

в клетке — доля броней с риском отмены не ниже 0,17; предоплата, если таких больше половины

	до 7 дней	8–30 дней	31–90 дней	91–180 дней	181–365 дней	больше года
Онлайн-агентства	12 %	77 %	93 %	94 %	94 %	·
Бесплатные	19 %	48 %	·	·	·	·
Корпоративные	6 %	40 %	59 %	·	·	·
Прямые	4 %	39 %	58 %	55 %	60 %	·
Группы	11 %	44 %	49 %	58 %	49 %	58 %
Авиакомпании	14 %	·	·	·	·	·
Офлайн-агентства	2 %	13 %	24 %	29 %	36 %	38 %

Брать: онлайн-агентства — бронь больше чем за неделю; прямые — больше чем за месяц; корпоративные — за 31–90 дней; группы — за 91–180 дней и больше года. **Не брать:** брони за неделю до заезда и через офлайн-агентства.

Ожидаемый эффект за год

≈ +2,9 млн €

от 2,0 (как в 2016 году) до 3,3 (с ростом броней на 14 %); 2,9 — по последним 12 месяцам. За 4 месяца экзамена: +1,55.

Зачем

Модель для проверки не видела последних месяцев 2017 года. На 2018 год она обучена заново на всех трёх годах, с теми же настройками.

под предоплатой	68 % броней вместо 70 %
таблица правила	решение сменилось в 1 из 19 клеток
качество	опора — 0,626 первой модели: экзамен вошёл в обучение

Оценка при допущениях: сокращение потерь — как на экзамене (73 %), денежные доли 50 % и 10 %. Вклад самой модели сверх предоплаты со всех — около 0,15 млн € в год.

Запасной слайд для вопросов

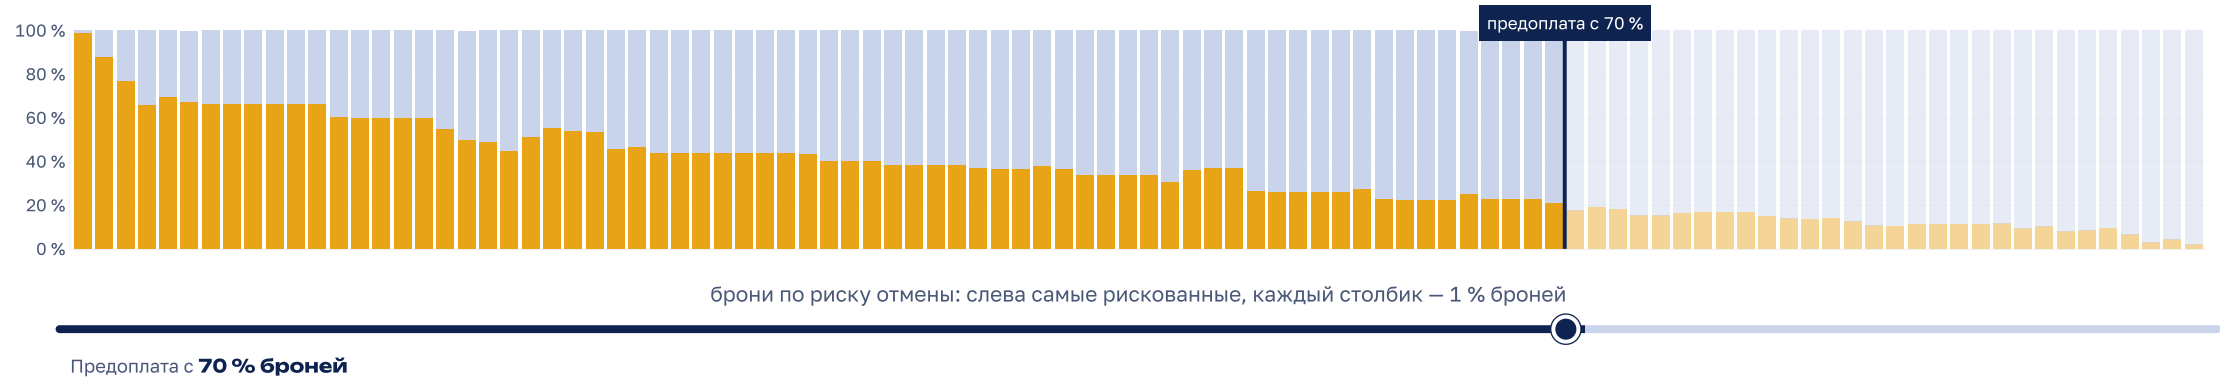
Дашборд проекта: отель, сегменты и допущения — и сразу деньги

Отмены броней | Дашборд | Презентация | Оба отеля | Городской | Курортный | Все сегменты | Май–август 2017 | Допущения

Потери с предоплатой по модели	Предоплата с	Отмен поймано	Надёжных гостей задето	Экономия против правила по сроку брони	Номеров сверх брони	Гостям не хватило номера	Дат, когда номера хватило всем
0,56 млн €	**70 % броней**	**90 %**	**60 %**	**0,23 млн €**	**≈ 41 в день**	**90**	**85,1 %**
без предоплаты 2,11 млн € со всех 0,64 млн €	порог риска 0,17	5 251 бронь	6 694 брони		по датам 21–63	перепродано 4 898	без модели 97,9 %

Очередь броней по риску отмены

Шафран — доля броней, которые на деле отменили. Левее черты берём предоплату.



Потери от доли броней с предоплатой

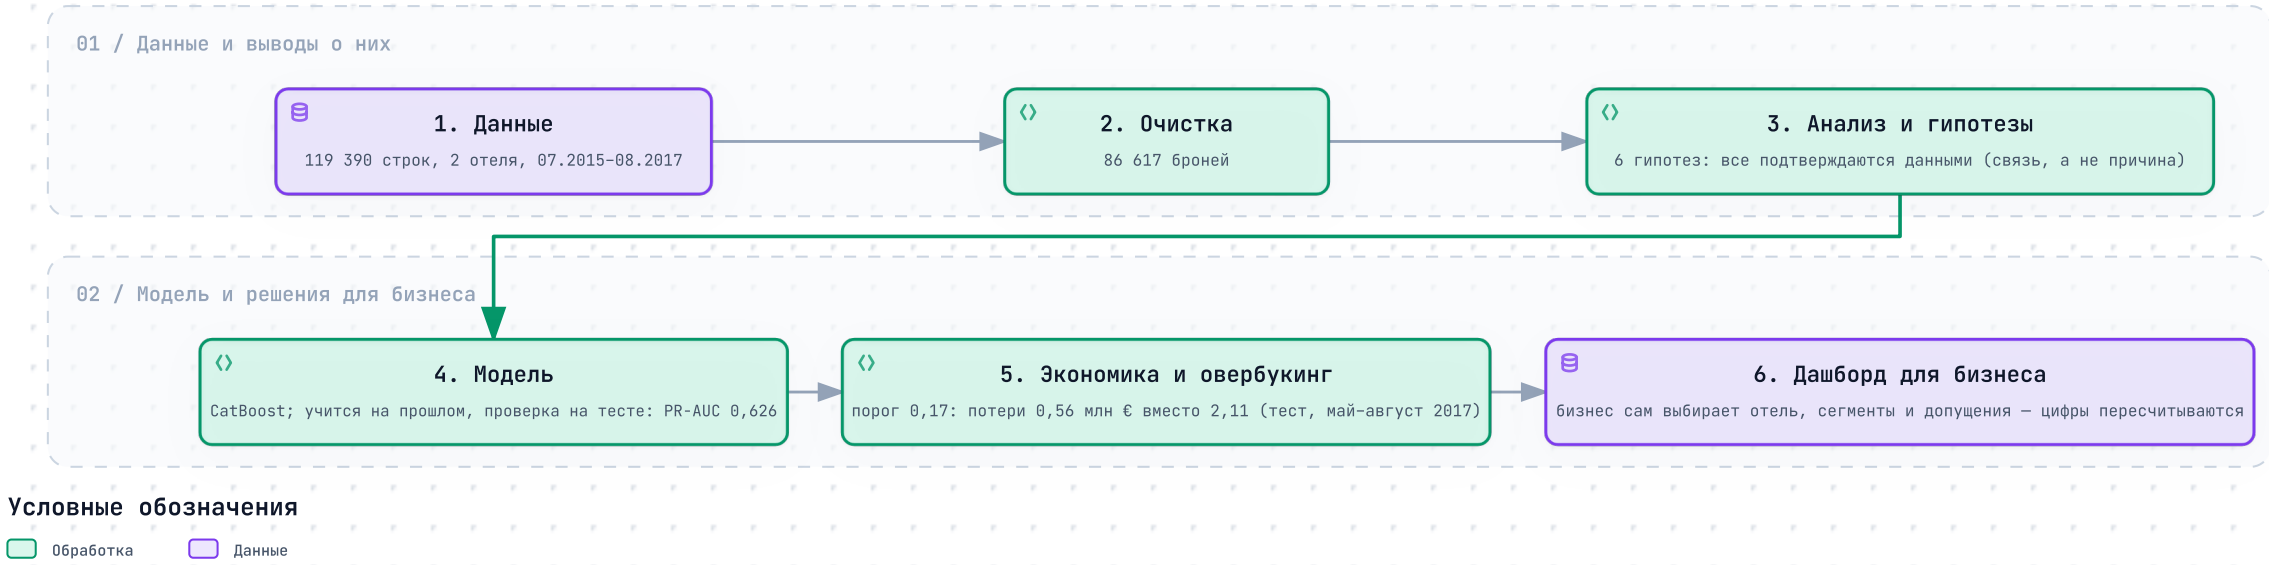
Модель против правила «брать предоплату с самых ранних броней».

Овербукинг по неделям заезда

Оба отеля, каждый считает сам.

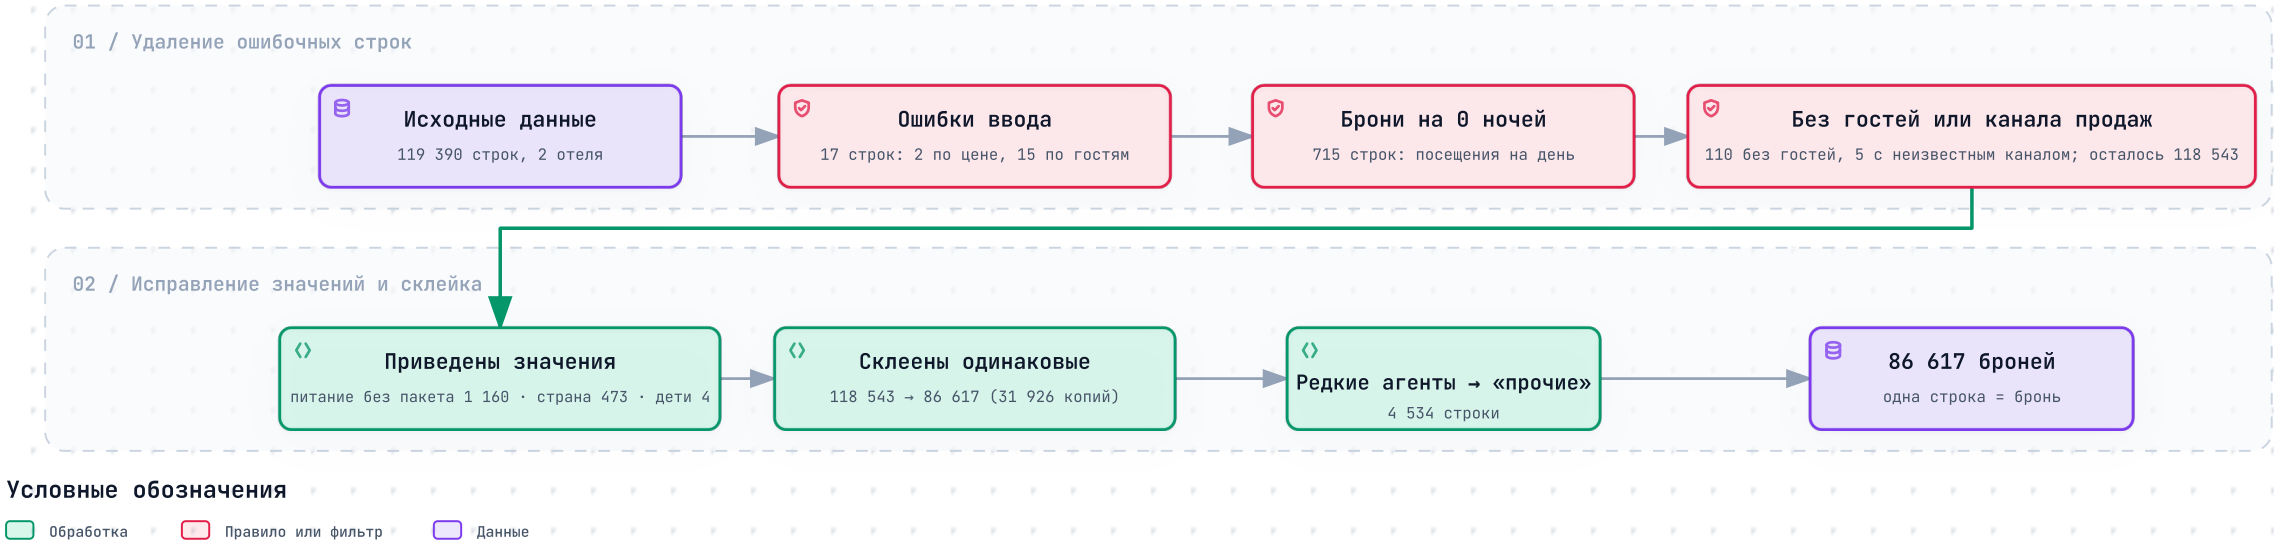
Запасной слайд для вопросов

Ход работы: от данных до дашборда



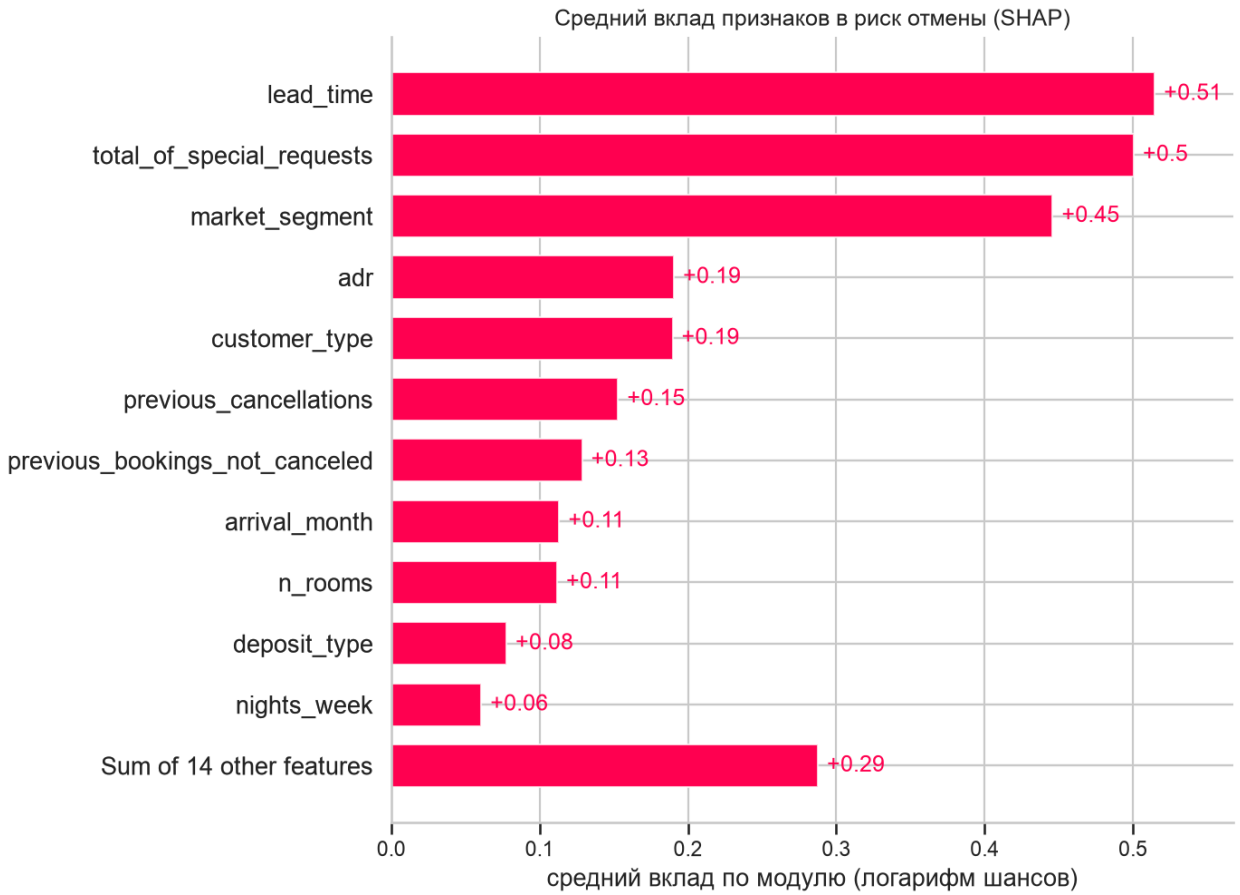
Запасной слайд для вопросов

Очистка данных: от 119 390 строк до 86 617 броней



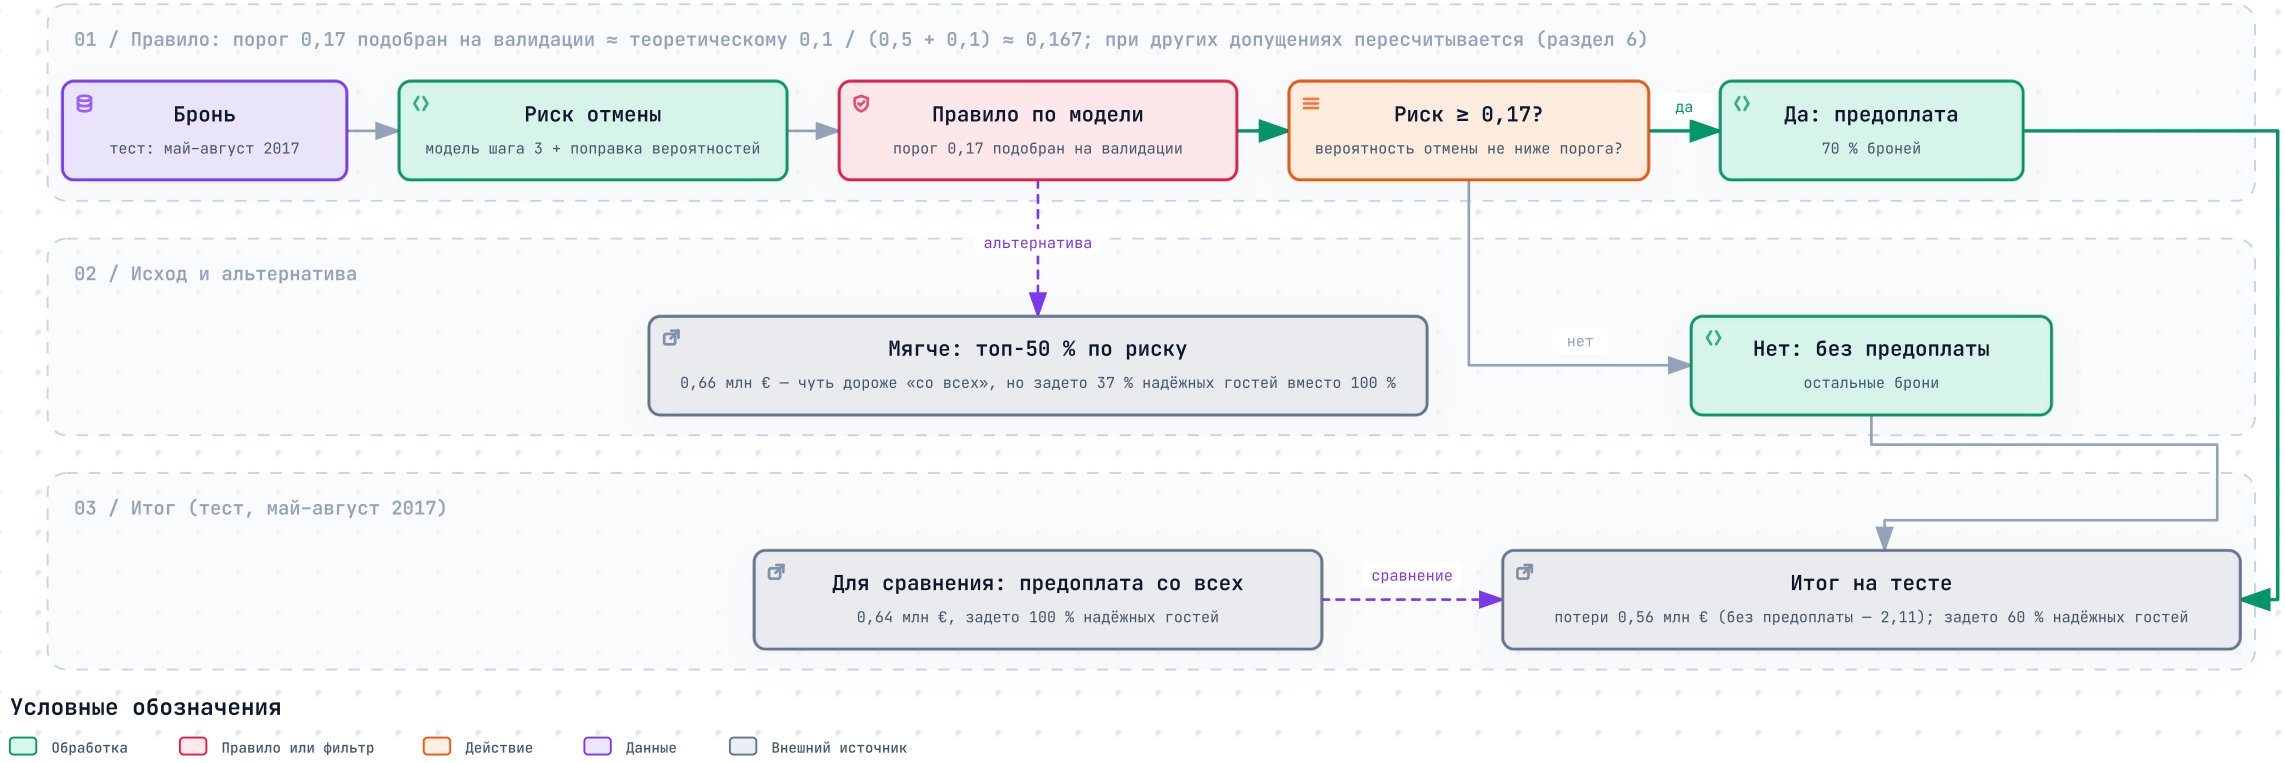
Запасной слайд для вопросов

Сильнее всего риск отмены определяют срок брони и спецзапросы



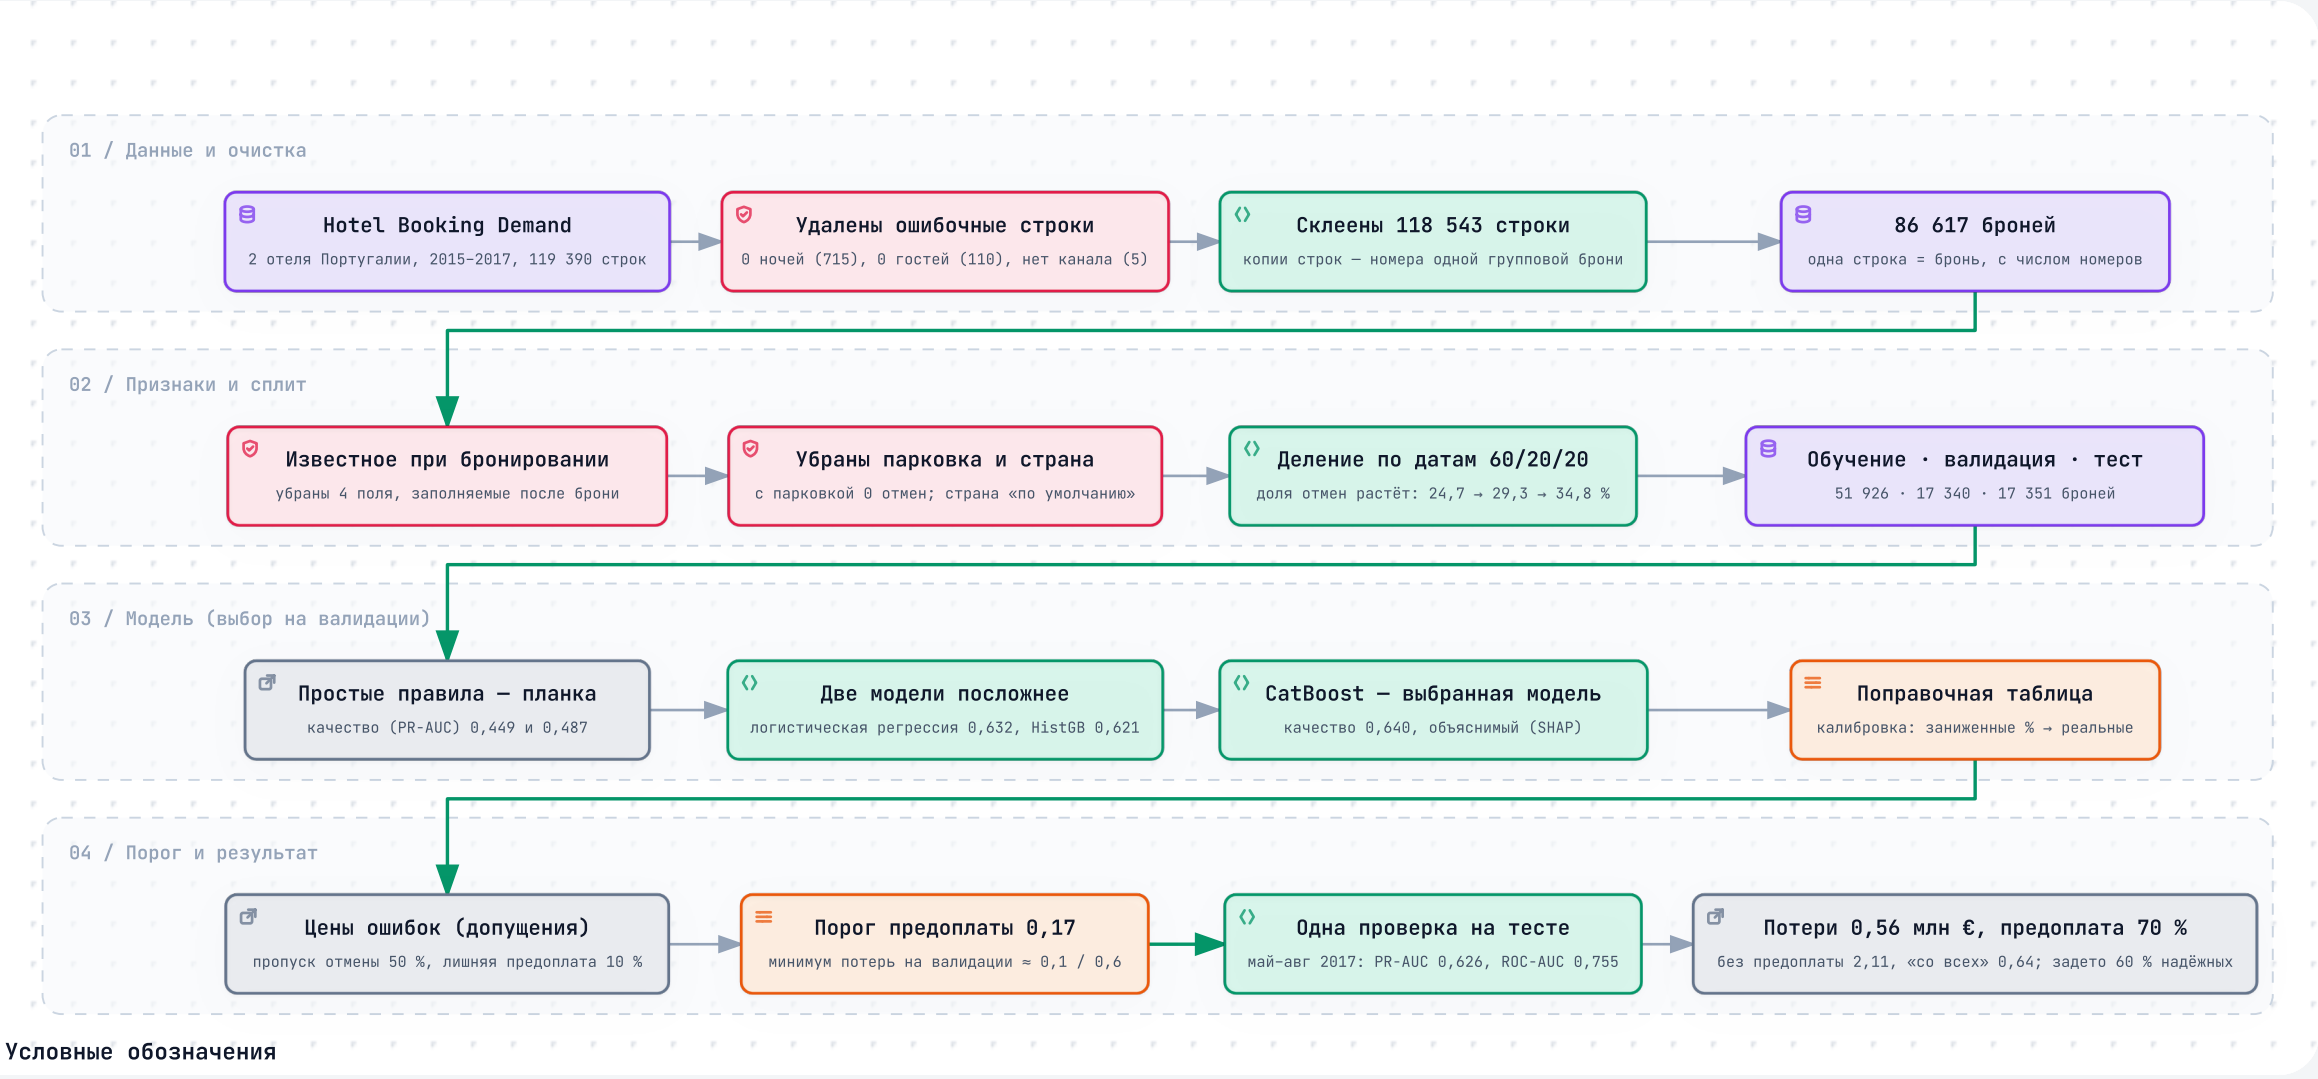
Запасной слайд для вопросов

Как принимается решение о предоплате



Запасной слайд для вопросов

Как собрана модель



Условные обозначения

Запасной слайд для вопросов

Как устроен код

